

Resumen semana 1

Inteligencia Artificial

Jose Ignacio Calderón Díaz

I. NOTICIA DE LA SEMANA

Majorana 1 es el primer chip cuántico del mundo desarrollado por Microsoft, basado en una arquitectura de núcleo topológico que utiliza un material innovador llamado topoconductor. Este avance permite la creación de cúbits más estables y escalables, esenciales para la computación cuántica. Con Majorana 1, se espera que los ordenadores cuánticos puedan resolver problemas complejos a escala industrial en años, en lugar de décadas.

II. GENERALIDADES

Durante la pandemia hubo un incremento considerable en los roles de ingeniería de software en la industria. Con los avances de la inteligencia artificial, se evidencia que esta invade los nichos del trabajo y puede realizar tareas con un grado alto de confiabilidad. En el paper 'SWE-Lancer: Can Frontier LLMs Earn \$1 Million from Real-World Freelance Software Engineering?' demuestra el alto valor de esta tecnología y es un indicador de la dirección que toma la industria e investigación.

Antes se pensaba que la IA era plantear todos los posibles casos de una situación o que eran como los árboles de decisión. Sin embargo, la IA es lejano a eso, esta intenta aproximar una función matemática para descubrir los posibles resultados. Por lo tanto, la calidad de los datos es importante.

La IA trae problemas éticos, por ejemplo, el canal de YouTube FlowGPT. Este creaba música a partir de veces de artistas con letra propia usando inteligencia artificial. La pregunta que salta es, ¿De quien son los derechos de autor?

III. INTRODUCCIÓN A LA INTELIGENCIA ARTIFICIAL

A. Machine learning

Se le acuña el concepto de ML a Arthur Samuel. Trabajo en IBM y realizo un algoritmo que simula una IA para jugar damas chinas.

El machine learning se define como la acción de construir máquinas que puedan hacer tareas sin que a estas se les diga que tiene que hacer o el como hacerlo, solo se le infiere los datos.

El modelo aprende a interpretar los datos de entrada. Solo recibe el input y las etiquetas.

El objetivo es crear un algoritmo para aproximar una función, similar a la mente humana. Por ejemplo la función que identifica gatos y perros.

Todos los algoritmos son estadística aplicada y heredan sus errores.

Existen dos aristas: ciencia e ingeniería

B. Machine Learning desde la ciencia

Tiene como objetivo generar conocimiento, crear nuevos modelos y optimizar. Se basa en métricas y se elige el mejor modelo según estas.

El rol de research scientist y data scientist se encarga de ver artículos, replicar los resultados y mejorarlos, hacer papers.

Estos roles no les preocupa utilizar los estándares de la industria como patrones o paradigmas de programación.

Se recomienda el paper: Towards an AI co-scientist.

C. Machine Learning desde la ingeniería

Tiene como objetivo poner los modelos en producción, limpiar y mejorar el código de los científicos de datos. Con el fin de dar mantenimiento y escalabilidad.

Utilizan herramientas como Onnx que toma un código y lo transforma en una optimización con técnicas como destilación o quantization.

Los MLOps pueden ser utilizadas cuando ocurre un data shift, cuando un modelo con distribución normal presenta un corrimiento en la distribución de datos. Cuando esto sucede se vuelve a entrenar el modelo con los nuevos datos.

Se realiza validación de los modelos, con 2 data sets uno para entrenamiento y el otro para validar.

En resumen, se puede ver estos conceptos como un diagrama de Venn.

- AI: es un programa que puede razonar y simular el comportamiento del ser humano.
- ML: algoritmos que ocupan datos para ser entrenados. El fin es aprender y mejorar el rendimiento.
- DL: Hace algoritmos multicapa de redes neuronales para aprender a resolver tareas. Requiere alto volumen de datos.

IV. TIPOS DE APRENDIZAJE

A. Aprendizaje Supervisado

Se entrena el modelo con un conjunto de datos etiquetado, donde cada entrada x tiene una salida esperada y . El algoritmo aprende ajustando sus predicciones para minimizar el error entre su salida y la etiqueta real.

Ejemplo: clasificación de correos electrónicos como "spam" o "no spam".

B. Aprendizaje No Supervisado

No se cuenta con etiquetas, solo con datos sin clasificar. Se utilizan técnicas como **clustering** (agrupamiento) para encontrar patrones en los datos.

Ejemplo: el algoritmo k -means agrupa clientes según su comportamiento de compra.

C. Aprendizaje Semi-Supervisado

Se dispone de un conjunto de datos donde solo una parte está etiquetada. Se aplican técnicas para inferir etiquetas en los datos no etiquetados y mejorar el aprendizaje.

Ejemplo: un dataset de 100,000 imágenes donde solo el 30% tiene etiquetas; el modelo usa estas para clasificar el resto.

D. Aprendizaje Auto-Supervisado

El propio modelo genera sus etiquetas a partir de los datos sin intervención humana.

Ejemplo: los **autoencoders**, que convierten imágenes en vectores latentes y luego reconstruyen la imagen original.

E. Aprendizaje por Refuerzo

Un agente aprende mediante prueba y error, recibiendo **recompensas** cuando realiza acciones correctas. Se usa en tareas donde no hay una única respuesta correcta, sino estrategias óptimas a descubrir.

Ejemplo: algoritmos que aprenden a jugar videojuegos superando niveles y optimizando su desempeño.

F. Few-Shot, One-Shot y Zero-Shot Learning

Estos términos describen la cantidad de ejemplos necesarios para que un modelo aprenda una tarea:

- **Few-Shot Learning:** el modelo necesita pocas muestras para generalizar.
- **One-Shot Learning:** aprende con un solo ejemplo.
- **Zero-Shot Learning:** el modelo resuelve una tarea sin haber recibido ejemplos previos específicos, basándose en conocimiento previo.

V. MACHINE LEARNING PIPELINE

- **Data acquisition:** etapa donde se obtienen los datos de calidad, paso importante.
- **Data preparation:** preparar los datos para obtener un data set de calidad.
- **Feature engineering:** etapa donde a partir de datos tabulares se construyen nuevos datos.
- **Model selection:** Seleccionar adecuadamente el modelo para el problema, no todo es LLMs.
- **Model training:** Se varían las métricas durante el entrenamiento.
- **Model deployment:** Etapa donde se define como se presenta el modelo.