

# Apuntes Semana 11 - 08/05/2025

Deylan Sandoval Sanchez - 2020234274  
Escuela de Ingeniería en Computación  
Instituto Tecnológico de Costa Rica

## I. ARQUITECTURAS CONVOLUCIONALES

### A. Composición

- \* Convolutional Layer: Encargadas de extraer las características de las imágenes
- \* Pooling Layer: Procesamiento para reducir el tamaño de la imagen
- \* Dense Layer: Tomar las características extraídas y hacer un clasificador




Fig. 1. Composición

$INPUT \rightarrow [[Cconv - relu] * nPool?] * m \rightarrow [fc \rightarrow relu] * k \rightarrow fc$   
 $3 \geq n \geq 0, m \geq 0, k \geq 0$   
 Stacks

### B. ¿Que arquitectura preferimos?

- Prefiera stacks con convoluciones pequeñas
- Las neuronas sera computadas con una función lineal directamente con la entrada, en el otro caso el stack contiene no linealidad (RELU) que hacen los features mas expresivos.
- Supongamos que todos los volúmenes tienen C canales, la convolución 7x7 tendrá  $C \times (7 \times 7 \times C) = 49C^3$  parámetros, El stack tendría  $(3 \times (C \times (3 \times 3 \times c))) = 27C^2$

### C. Algunas Reglas

- \* El tamaño de la capa de entrada (contiene la imagen) debería ser divisible por 2 muchas veces
- \* Las capas de convoluciones debería usar campos receptivos pequeños 3x3 o a lo mucho 5x5, utilizando stride = 1
- \* Padding de ceros de manera que no se altere el espacio
- \* Configuraciones comunes de maxpooling es F = 2, S = 2 o F = 3, S = 2

Se empieza con una base de datos que va a contener aproximadamente 60.000 muestras donde cada una son imágenes de 28x28 píxeles, cada píxel será un feature por lo tanto se tiene 784 features, en cada imagen se encuentra un dígito escrito a mano, por lo que cada dígito va a ser diferente aunque sea el mismo número, el objetivo va a ser tratar de hacer un clasificador de números escritos a mano

## D. Arquitecturas

### \* LeNet




Fig. 2. Arquitectura LeNet

### \* AlexNet




Fig. 3. Arquitectura AlexNet

### \* ZFnet




Fig. 4. Arquitectura ZFNET

### \* GoogleNet




Fig. 5. Arquitectura GoogleNet

### \* VGG16




Fig. 6. Arquitectura VGG16

### \* ResNet




Fig. 7. Arquitectura ResNet

\* DenseNet




Fig. 8. Arquitectura DenseNet

### E. Visualizando que aprenden las redes convolucionales

:

1) *Problemas de las redes neuronales*: \* Dificiles de explicarla

\* Features aprendidos no son interpretables

2) *Tecnicas para analizar las redes*: :

\* Visualizar las activaciones: Se muestran las activaciones al momento de la pasada hacia adelante, se pueden ver la neuronas muertas(ReLU)

\* Visualizar los filtros: Se visualizan los pesos, se interpretan mejor en la primera capa convolucional y muestran los filtros sin patrones de ruidos

### F. Embeddings

\* Gradualmente transformamos imágenes a una interpretación( vector), sus clases son separables por un clasificador

\* Se pueden transformar a una representación de dimensión menor manteniendo distancias iguales que la representación mayor, t-SNE (paper para la tecnica)




Fig. 9. Embeddings

## II. AUTOENCODER

Se basan en la reconstrucción de una imagen con un vector de características, es supervisando pero con la misma imagen de entrada, por eso se entra en un debate y se clasifica como no-supervisado

Esta compuesto por:

\* Encoder: Extrae la características de la imagen

\* Espacio latente: Distribuye las características de la imagen

\* Decoder: Reconstruye la imagen




Fig. 10. Autoencoder

¿Que puede hacer un Autoencoder?

\* Permite representar la entrada en un vector mas pequeño

\* Representación mas poderosa en comparación con PCA

\* Permite reconstruir la información con menos perdida