Apuntes Semana 13 - 20/05/2025

Sebastián Vargas Mesén

I. RESPUESTAS DEL QUIZ

1) Describa qué es una capa de convolución y una capa de pooling.

Respuesta: Una capa de convolución es aquella que extrae los features (características) relevantes de la imagen mediante la aplicación de kernels (filtros). Cada filtro recorre la imagen realizando multiplicaciones y sumas para detectar patrones como bordes, texturas o formas.

La capa de pooling es aquella que tiene como objetivo reducir la dimensionalidad de la imagen a procesar, manteniendo la dimensionalidad de la profundidad. Ayuda a disminuir el número de parámetros y el tiempo de cómputo sin afectar los canales/profundidad.

2) Mencione dos ventajas por las cuales se prefiere aplicar pequeñas convoluciones anidadas en lugar de una convolución grande, si su salida fuera equivalente.

Respuesta: Dos ventajas son:

1. La menor cantidad de parámetros necesarios para extraer la información
2. Una mayor capacidad de analizar la imagen, ya que se utilizan funciones no lineales entre cada capa

3) Describa parte por parte un módulo de Inception.

Respuesta:

- **a) Convolución 1x1:** Aplica filtros de tamaño 1x1 sobre la entrada
- **b) Convolución 3x3:** Aplica filtros 3x3 para captar patrones espaciales medianos
- **c) Convolución 5x5:** Aplica filtros 5x5 para captar patrones más grandes
- **d) 3x3 MaxPooling:** Realiza una operación de pooling sobre la entrada

4) Describa qué es cada variable (m, k, p, s) en la siguiente fórmula para el cálculo de dimensiones.

$$\frac{m-k+2p}{s+1} = \ Dimensión\ resultado$$

Respuesta:

- **m** = tamaño de la entrada (input)
- **k** = tamaño del kernel (filtro)
- **p** = padding (relleno)
- **s** = stride (salto del filtro)

II. REPASO

A. Autoencoders

Los autoencoders hay debate si son de aprendizaje no supervisado o si son de aprendizaje supervisado, ya que estos se

basan en la reconstrucción de una imagen.

El autoencoder es supervisado con la misma imagen que se le dio como entrada, ya que este reconstruye la data que venía de entrada, hay una nube gris en determinar si es supervisado o si no es supervisado ya que solo usa la entrada mas no hay etiquetas.

En la literatura en su mayoría se le asigna como no supervisado ya que usa la misma entrada de x para su aprendizaje.

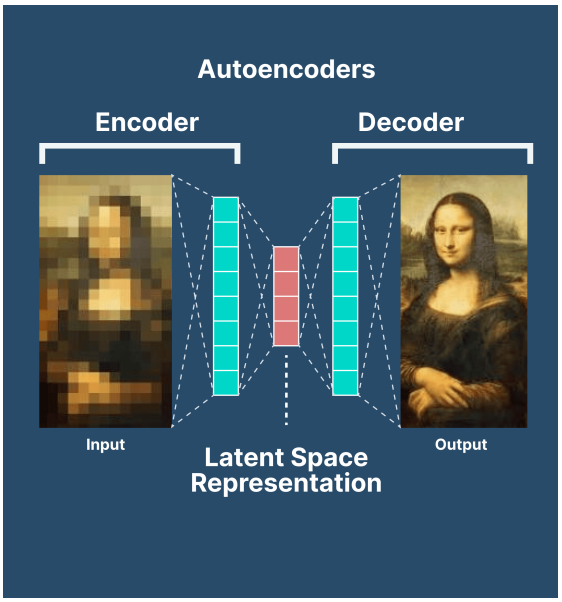

Hay 3 partes que lo componen:

- **Encoder:** extrae características de imagen
- **Espacio latente o cuello de botella:** vector de características es distribuido
- **Decoder:** A partir de los embeddings se reconstruye la imagen

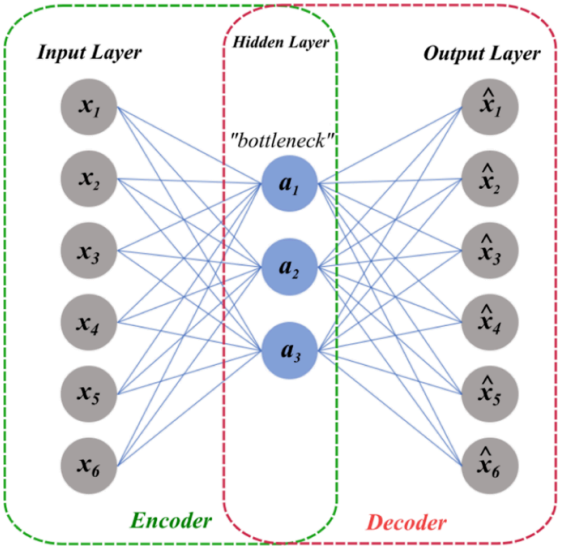

Figura 2. Estructura autoencoder

Nota: La imagen no queda exactamente igual, ya que esta es reconstruida a partir de una imagen a partir de un vector más pequeño, mientras más grande sea el vector, más similar será la imagen. Este concepto se puede aplicar a cualquier tipo de red neuronal.

Aplicaciones Principales:

1) Reducción de dimensionalidad

La reducción de dimensionalidad permite representar la entrada de un vector más compacto, además que es más poderosa en comparación con PCA y permite reconstruir la información con menos pérdida.

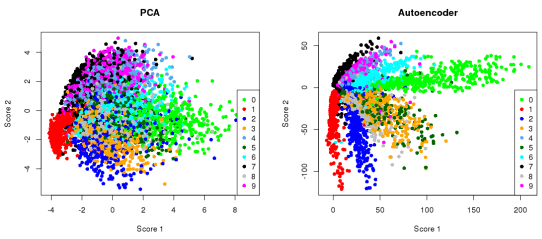

2) Detección de anomalías

El modelo se entrena para reconstrucción de datos en una tarea tomando en cuenta

su estado positivo, que es usado para validar transferencias bancarias correctas y es de alta fidelidad. Además aprende la representación latente de casos positivos. Si una transferencia es suficientemente distinta a la normal, el auto-encoder (encoder) generará un vector latente deficiente, el cual no se puede reconstruir.

El function loss será muy alto al momento de la reconstrucción y se debe definir un umbral para marcarlo como fraudulento.

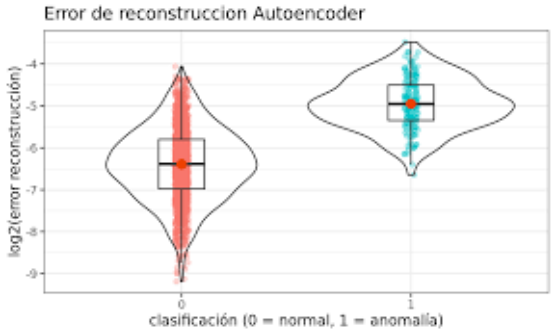

3) Procesamiento de imágenes

Se puede utilizar para la compresión de imágenes, reducir el ruido de las mismas además de aumentar la resolución en la cuales a partir de imágenes de baja resolución se aumenta la resolución usando técnicas como upscaling y así mismo se puede hacer reconocimiento facial en imágenes de baja resolución.

III. ENCODER

Este es un conjunto de bloques convolucionales seguidos de módulos de pooling que es aplicar técnicas de convolución hasta reducir una imagen y tener feature maps que se convierten en un vector. Este se encarga de la extracción de características de imagen y comprime la información. La idea es obtener un vector latente el cual se le conoce como downsampling, que es lo que le permite representar la imagen de entrada en algún punto en el espacio.

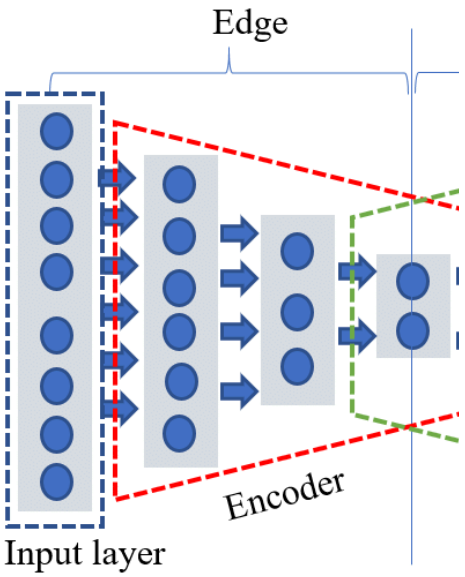

IV. CUELLO DE BOTELLA

Es la parte más importante y pequeña del modelo, si este espacio latente está mal hecho el autoencoder no va a funcionar correctamente.

Posee representación en espacio latente.

Restringe el flujo de la información proveniente del encoder al autoencoder, que es la reducción de la dimensionalidad pasado al decoder.

A medida que el entrenamiento mejora, se van separando más los datos formando tipo clusters de las cosas más similares juntas.

V. DECODER

Este vendría siendo las convoluciones que hacen upsampling y a partir de aquí

se empieza a reconstruir la imagen basado en el vector latente.

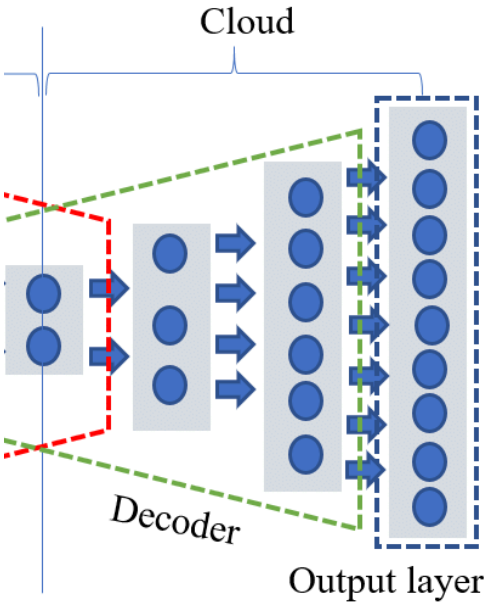

VI. HIPERPARÁMETROS A CONSIDERAR

El tamaño de la codificación (vector latente)

Va a depender de la arquitectura entre más entradas tenga el vector, mayor es la información y es mayor la compresión (a mayor tamaño mayor costo de procesamiento).

El número de capas a utilizar

Sigue el principio de a mayor número de capas mejores resultados se van a obtener, pero es más complejo es el modelo y se puede overfitear y la capacidad de inferencia disminuye.

Para la reconstrucción

Es totalmente dependiente de la entrada y la salida, se usa MSE para comparar cada uno de los píxeles que deberían de ser iguales tanto en la entrada como en la salida y el binaryCrossEntropy entre los valores de rangos [0,1].

VII. TIPOS DE AUTOENCODER

A. Undercomplete Autoencoder

Este tipo de modelo toma la imagen de entrada e intenta predecir la misma imagen de salida. La dimensión del espacio latente es menor que el espacio de entrada.

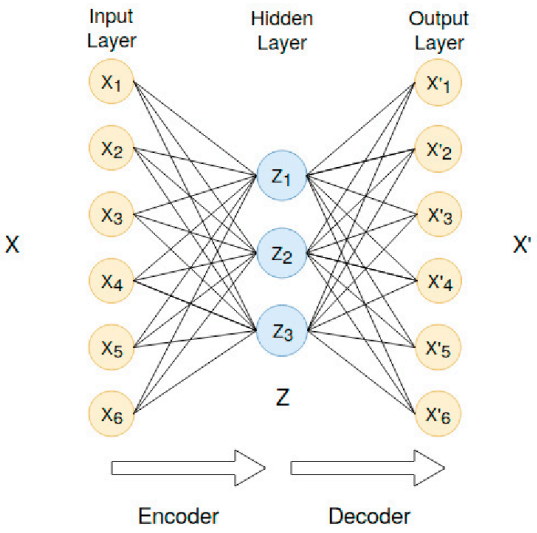

B. Sparse Autoencoder

No va a tratar de reducir la dimensionalidad, sino apagar ciertas neuronas para aprender a hacer el vector tipo haciendo dropout a cada una de las neuronas. Selectivamente apaga las neuronas de la red.

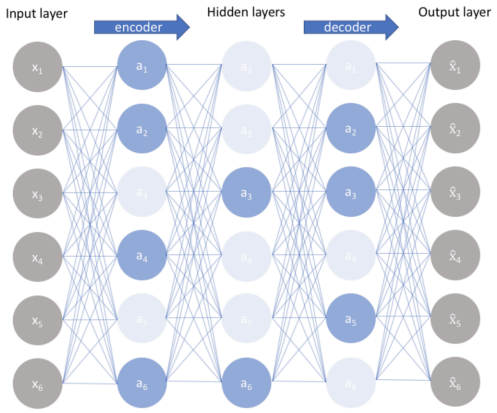

C. Denoising Autoencoder

Este es un modelo utilizado para remover el ruido de una imagen y su salida no tiene la imagen de entrada.

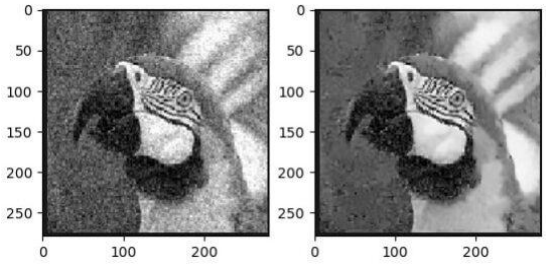

D. Variational Autoencoder

Los autoencoders estándar aprenden a representar los datos en un espacio latente, pero este espacio no es necesariamente continuo ni estructurado.

Generalmente, el vector latente de un autoencoder tradicional no sigue ninguna distribución específica; simplemente contiene valores aprendidos durante el entrenamiento. Esto puede dificultar la **interpolación** (es decir, estimar valores intermedios entre puntos conocidos del espacio latente), ya que no existe una estructura probabilística que relacione los distintos puntos.

Para solucionar este problema, se utiliza el Variational Autoencoder. Este aprende a representar los datos en el espacio latente de manera probabilística, forzando a que los vectores latentes sigan una distribución. Esto permite interpolar y generar datos nuevos de forma más sencilla y coherente, haciendo el espacio latente continuo y útil para tareas generativas.

Para hacer el variational autoencoder es necesario producir que los vectores sigan una distribución normal con media μ y desviación estándar específica. El codificador produce 2 vectores para hacer la distribución la cual es la representación de μ y σ estándar. Se hace una reparametrización, donde se toman las muestras de μ y σ estándar para poder producir el vector latente y una vez hecho esto se toma el vector latente y se alimenta el decoder.

Nota: la función de pérdida es la suma del Binary Cross Entropy y la de Kullback-leibler Divergence.

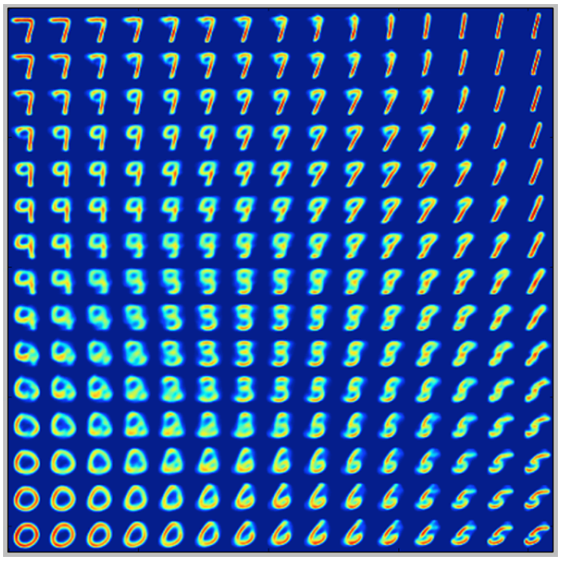

IX. AUTOENCODER SEGMENTACIÓN

Se utiliza la arquitectura U-Net, esta tiene forma de "U" y se basa en el principio de

los autoencoders. U-Net es especialmente popular en tareas de segmentación de imágenes médicas y científicas.Sus principales partes son:

Encoder

Similar a un autoencoder tradicional, esta parte se encarga de extraer las características principales de la imagen de entrada, reduciendo progresivamente su tamaño a través de capas de convolución y pooling.

Decoder

Esta parte reconstruye la imagen segmentada a partir de la representación comprimida, utilizando capas de upsampling que permite hacer la segmentación y la entrada y salida son diferentes porque la salida se compara con el ground truth de la segmentación aplicada.

Skip Connections

Una característica clave de U-Net es el uso de skip connections, que unen las capas del encoder y decoder en niveles correspondientes. Esto permite reconstruir mucho mejor las imágenes que se están procesando.

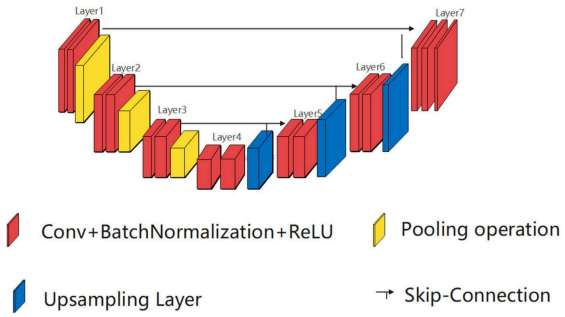

Conclusiones

Los autoencoders son redes neuronales versátiles que aprenden representaciones comprimidas de datos para posteriormente reconstruirlos. Su capacidad de operar sin etiquetas los hace especialmente útiles para:

- **Reducción de dimensionalidad** más poderosa que métodos lineales
- **Detección de anomalías** mediante análisis de errores de reconstrucción
- **Mejoramiento de imágenes** (denoising, super-resolución)
- **Generación de datos** (especialmente con VAE)
- **Segmentación precisa** (con arquitecturas como U-Net)

La selección del tipo de autoencoder y sus hiperparámetros debe basarse en la tarea específica y las características de los datos disponibles.